Steam Database: Analisis exploratorio y preprocesamiento

1ro David Felipe Marin Rosas
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
dmarinro@unal.edu.co

2do Gian Emanuel Morales González
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
gimoralesg@unal.edu.co

3ro Juan Felipe Bejarano Salazar
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
jbejaranos@unal.edu.co

4to Luis Esteban León Rojas
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
luleonr@unal.edu.co

***Abstract*—This document details the exploratory data analysis and preprocessing of the "Steam Games Dataset", which contains information from over 120,000 video games published on the Steam platform. The objective is to analyze its features (prices, concurrent players, reviews, genres) to build a clean and ready-to-use dataset for predictive models. Through visualizations and robust statistical measures, it was identified that the market exhibits a strong asymmetry: there is a vast number of low-impact free games compared to a small number of massive hits. These findings guided the data cleaning process, null value handling, and feature engineering, setting the groundwork to predict the commercial success of future video games in a structured manner.**

***Index Terms*—videojuegos, análisis exploratorio, preprocesamiento, steam database, python, pandas, matplotlib, seaborn, patrones de compra, tendencias de juego, comportamiento del consumidor**

I. Introducción

En la última década, la industria de los videojuegos ha experimentado un crecimiento exponencial, consolidándose como uno de los sectores de entretenimiento más lucrativos a nivel global. Dentro de este ecosistema, Steam, operada por Valve Corporation, se mantiene como la plataforma de distribución digital dominante para PC. Con miles de títulos lanzados anualmente, la plataforma genera un volumen masivo de datos que reflejan tendencias de consumo, estrategias de precios y preferencias de género.

El presente documento se centra en el estudio del "Steam Games Dataset", una recopilación de datos a partir de la API ofrecida por steam. Este conjunto de datos captura la diversidad del catálogo de Steam, permitiendo observar desde grandes producciones AAA hasta el emergente mercado de juegos independientes (Indie).

II. Objetivo

Analizar qué variables del conjunto de datos influyen más en el éxito de un videojuego. Para este estudio, nuestras tres variables esenciales y métricas de éxito serán: el porcentaje de reseñas positivas categorizado (indicando cantidad total y la razón de aprobación), el número de ventas (*Estimated owners*), y la cantidad de jugadores simultáneos (*Peak CCU*). Con esto, se busca sentar las bases para crear modelos predictivos que estimen el éxito comercial de futuros desarrollos y descubrir qué características se necesitan para triunfar dentro de nichos específicos de mercado.

III. Descripción del conjunto de datos

Se utilizó el "Steam Games Dataset" [**?**], obtenido a partir de la API oficial de Steam. Este *dataset* cuenta con 122 611 registros, correspondientes cada uno a un videojuego único, y está compuesto por 39 variables originales.

Las variables abarcan diferentes tipos (ver Figura **??**): nominales absolutas como el identificador (*AppID*) y nombre (*Name*); de razón para características continuas como el precio (*Price*) y la máxima cantidad de jugadores simultáneos (*Peak CCU*); ordinales como la estimación de compradores (*Estimated owners*); y variables con múltiples valores nominales, como los géneros (*Genres*) y categorías (*Categories*).

IV. Análisis Exploratorio y Resultados

A. Análisis de Frecuencias y Medidas de Centralidad

En la exploración inicial, se observó que casi todos los juegos son compatibles con Windows, superando ampliamente a los desarrollos para Mac y Linux. Al revisar variables numéricas como el precio y el máximo de jugadores activos (*Peak CCU*), se evidenció que una porción muy pequeña de títulos acumula la gran mayoría de las cifras. Al existir tantos valores en cero o muy bajos, existe una enorme diferencia entre el promedio (media aritmética) y la mediana. Para mitigar el efecto de estos valores atípicos (*outliers*), se calculó la **media truncada** (*trimmed mean*), eliminando el 10% de los datos más extremos de cada lado para obtener el comportamiento de un juego más "típico".

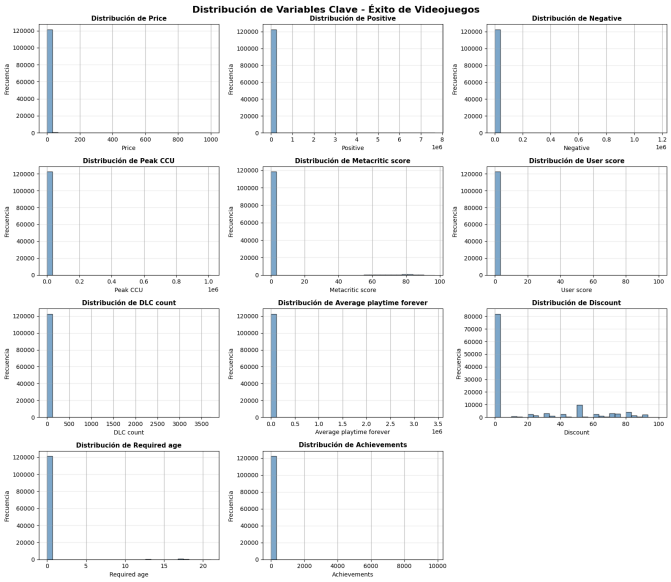

Fig. 1. Distribución de frecuencias para las variables numéricas de Steam. Se evidencia una gran asimetría hacia el lado izquierdo.

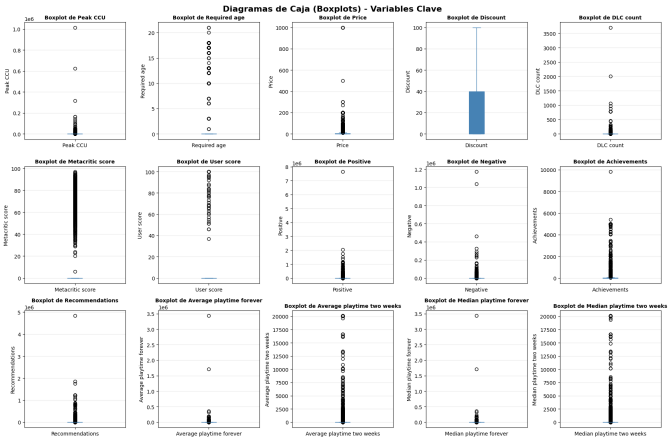

Fig. 2. Diagramas de caja (*Boxplots*) que muestran la gran cantidad de valores atípicos y la enorme dispersión generada por juegos sumamente populares.

B. Medidas de Dispersión y Distribuciones

Para medir correctamente la dispersión de los datos sin afectar la precisión matemática a causa de de los valores atípicos, se priorizó la **Desviación Media Absoluta (AAD)**. Como se observa en la estimación de densidad KDE y en los diagramas de caja (Figura **??**), atributos monetarios y de popularidad tienen una distribución marcadamente inclinada hacia la cota inferior. El mercado comercial se compone de innumerables títulos de bajo costo o completamente gratuitos con muy poco impacto, que contrastan fuertemente frente a las grandes y escasas franquicias *AAA* o juegos virales.

C. Causalidad Multivariada

Al utilizar medidas de correlación lineal (coeficiente de Pearson), se encontraron relaciones claras y fundamentales. Por ejemplo, existe una fuerte asociación directa entre la máxima cifra récord de jugadores (*Peak CCU*) y el volumen histórico de reseñas obtenidas (tanto positivas como negativas). Estos factores crecen directamente de acuerdo al volumen total de jugadores que atrae el título.

V. Preprocesamiento de Datos

Para asegurar que los datos del catálogo resulten óptimos para su uso en la fase de modelamiento algorítmico estadístico, se ejecutó un proceso riguroso de limpieza:

A. Selección y Eliminación de Atributos

Se descartaron todas las variables que no aportaban métricas relevantes para clasificar o predecir el éxito de un juego, tales como hipervínculos web, direcciones de correo de soporte y referencias multimedia promocionales (*Header image*, *Movies*, *Screenshots*). Adicionalmente, se eliminaron columnas que se encontraban casi completamente vacías o rellenas de valores en cero, como *User score* o *Required age*, ya que estas interferían con la integridad de los modelos predictivos.

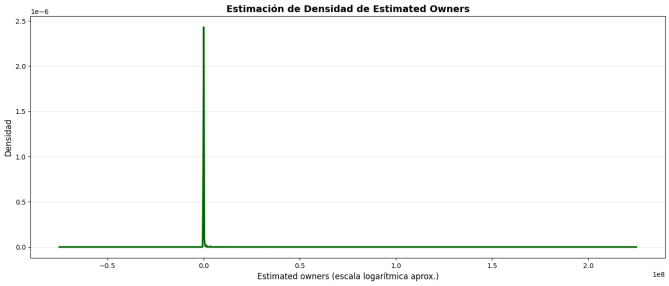

Fig. 3. Estimación de densidad (KDE) para visibilizar las frecuencias en los rangos discretos de la cantidad estimada de jugadores (*Estimated Owners*).

B. Tratamiento de Valores Faltantes (Nulos)

A través de la inspección sobre la ausencia de datos, se identificó que no figurar con un autor y empresa encargada (*Developer*) es comúnmente una señal relacionada a estafas o desarrollos falsos subidos a la red de Steam; por este motivo, se purgaron completamente las filas que carecían de dicho identificador. Por el contrario, es un comportamiento normal que las variables categóricas o descriptivas queden en blanco (ej. *Genres*, *Tags*, *Publishers*) debido a la forma de registro de algunos títulos. Estos casos orgánicos ausentes fueron cubiertos sistemáticamente con el identificador de texto "NA" para evitar corrupciones estructuradas. Toda métrica unívocamente matemática registró niveles completos, por lo que no existieron vacíos numéricos que imputar.

C. Ingeniería de Atributos y Discretización

El preprocesamiento del precio exhibía un desafío dada la enorme recurrencia de valores nominales fijados en $0.00. Para contrarrestarlo, la cifra escalar *Price* fue extraída bajo bandas de clasificación ordinales (*Price_category*), replicando las barreras comerciales comúnmente encontradas entre consumidores (juegos gratuitos, juegos muy baratos, o el tope tradicional de $59.99). De igual forma lógica, la cadena textual

Categorías	Reseñas mínimas	Tasa mínima
Overwhelmingly Positive	500	0,95
Very Positive	10	0,8
Mostly Positive	10	0,7
Mixed	10	0,4
Mostly Negative	10	0,2
Overwhelmingly Negative	500	0,2
Very Negative	50	0,2

Categorías	Ventas Máximas
Niche	20000
Small Indie	100000
Growing	500000
Popular	1000000
Very Popular	2000000
Top Game	10000000
Blockbuster	50000000

correspondiente a la fecha de publicación (*Release date*) se separó minuciosamente en tres diferentes campos tabulares: año, mes, y estación de lanzamiento. Esto habilitará la futura extracción estacional de picos de consumo anual.

D. Manejo Condicional de Valores Atípicos

La estrategia para atenuar valores atípicos se dictaminó con el algoritmo clásico del rango intercuartílico (IQR). En el campo preciso de los análisis tarifarios, se evidenció que aislar en dos sub-estratos independientes a los títulos “Gratuitos” en relación a aquellos de “Pago”, provocaba un impacto determinante para comprender o fijar el límite estadístico a partir de cuándo un valor era realmente un costo sumamente atípico. Referente a medidas de popularidad de éxito irruptivo tales como la congregación máxima histórica (*Peak CCU*), se optó intencionalmente por conservar intactos todos sus datos hiper-extendidos. Esto obedece a que limitar arbitrariamente dichos volúmenes resultaría en amputar a los protagonistas absolutos y al concepto fundamental del “éxito”, mermando completamente las proyecciones algorítmicas hacia los verdaderos gigantes del mercado de videojuegos.

E. Categorización de atributos

Para facilitar el análisis de las reseñas, se crearon nuevas columnas con información derivada. Para empezar se crearon las columnas `total_reviews` y `review_rate`. La primera es el total de reseñas que tiene un juego, mientras que la segunda es la tase de reseñas positivas, calculada con la división entre las reseñas positivas (*Positive*) y las reseñas totales. Con la tasa se realizó una categorización para manejar las reseñas, esta refleja la que se usa en la plataforma. Para empezar se analiza el número de reseñas, si son cero se asigna la categoría *No reviews*, y si son menos de diez se tiene *Too few reviews*. A partir de aquí, se toma la tasa para asignar las categorías además del número de reseñas.

También se creó una categorización para las ventas, con el atributo "No data" para aquellos juegos sin ventas. A partir de aquí se tienen las siguientes categorías:

Adicionalmente, se tiene la categoría "Mega Hit" para los juegos que tengan más de 50000000 de ventas.

Por último, también se tiene una categorización de desempeño con base en las métricas del pico de usuarios concurrentes ("Peak CCU") y la calificación de la página agregadora de reseñas Metacritic.

Para los usuarios concurrentes se realiza una clasificación por percentiles con los valores de 0.25, 0.5, 0.75 y 0.9. Estos definen las categorías, los juegos con un valor de 0 son asignados a la categoría "No activity", mientras que los demás se asignan a las categorías "Very Low", "Low", "Medium" y "High". Los juegos en el percentil más alto entran en la categoría "Very High".

Respecto a la calificación de Metacritic, la clasificación se hace teniendo en cuenta ciertos sesgos de la plataforma, donde la calificación de muchos juegos tiende a estar entre 50 y 100, y rara vez se otorga una clasificación menor a 50. Con esto en mente se tienen las categorías "Not rated" para juegos sin calificación, "Poor" para aquellos con menos de 50, "Mediocre" hasta 60, "Average" hasta 70, "Good" hasta 80, "Very Good" hasta 90 y "Excellent" para los juegos con una calificación entre 91 y 100.

F. Juegos de interés

Para analizar distintas tendencias se hizo una selección separada de ciertos juegos particularmente exitosos, estos fueron denominados como juegos de interés. Para seleccionar estos juegos se decidieron las medidas de reseñas y ventas, selecionando los juegos con reseñas de Steam en las categorías Overwhelmingly Positive o Very Positive, o ventas en las categorías Top Game, Blockbuster o Mega Hit.

G. Uso de One-Hot Encoding

Se realizó el One-Hot Encoding en los atributos de "Genres" y "Tags" para facilitar el análisis. Sobre los géneros se realizó la codifiación sobre los 33 géneros únicos del dataset, mientras que para las etiquetas solo se usaron aquellas que tengan al menos 5000 apariciones para evitar tener columnas demasiado dispersas, conservando 59 de las 452 etiquetas presentes en el dataset.

VI. Conclusión y Trabajos Futuros

Pendiente