

Steam Games Dataset: Procesamiento, Análisis Descriptivo, Asociación, Agrupamiento y Clasificación

1^{ro} David Felipe Marin Rosas
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
dmarinro@unal.edu.co

2^{do} Gian Emanuel Morales González
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
gimoralesg@unal.edu.co

3^{ro} Juan Felipe Bejarano Salazar
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
jbejaranos@unal.edu.co

4^{to} Luis Esteban León Rojas
Facultad de Ingeniería
Universidad Nacional De Colombia
Bogotá, Colombia
luleonr@unal.edu.co

Resumen—Steam es una de las plataformas de distribución digital de videojuegos más importantes del mundo y genera grandes volúmenes de información sobre comportamiento de usuarios, características de los juegos y métricas de éxito comercial. En este trabajo se realizó un análisis exploratorio y un proceso de preprocesamiento sobre el Steam Games Dataset, compuesto por más de 122 000 títulos. Inicialmente se caracterizó estadísticamente el conjunto de datos, identificando distribuciones altamente asimétricas, una fuerte presencia de valores atípicos y diferencias marcadas entre juegos de nicho y títulos de gran popularidad. Posteriormente se aplicaron técnicas de limpieza, tratamiento de valores faltantes, ingeniería de atributos y codificación de variables categóricas. Sobre los datos procesados se desarrollaron análisis de reglas de asociación, agrupamiento y clasificación supervisada con el fin de identificar patrones relacionados con el éxito de los videojuegos. Los resultados evidencian asociaciones significativas entre determinadas características de los juegos y métricas como ventas, volumen de reseñas y actividad de usuarios, además de permitir la identificación de perfiles comerciales diferenciados dentro de la plataforma. Asimismo, los modelos de clasificación demostraron la importancia de estrategias adecuadas para el manejo del desbalance de clases. Este trabajo establece una base para el desarrollo de modelos predictivos y herramientas de apoyo a la toma de decisiones dentro de la industria de los videojuegos.

Index Terms—Steam, videojuegos, minería de datos, aprendizaje automático, reglas de asociación, clustering, clasificación.

I. INTRODUCCIÓN

En la última década, la industria de los videojuegos ha experimentado un crecimiento exponencial, consolidándose como uno de los sectores de entretenimiento más lucrativos a nivel global. Dentro de este ecosistema, Steam, operada por Valve Corporation, se mantiene como la plataforma de distribución digital dominante para PC. Con miles de títulos lanzados anualmente, la plataforma genera un volumen masivo

de datos que reflejan tendencias de consumo, estrategias de precios y preferencias de género.

El presente documento se centra en el estudio del "Steam Games Dataset", una recopilación de datos a partir de la API ofrecida por steam. Este conjunto de datos captura la diversidad del catálogo de Steam, permitiendo observar desde grandes producciones AAA hasta el emergente mercado de juegos independientes (Indie).

II. OBJETIVO

Analizar qué variables del conjunto de datos influyen más en el éxito de un videojuego. Para este estudio, nuestras tres variables esenciales y métricas de éxito serán: el porcentaje de reseñas positivas categorizado (indicando cantidad total y la razón de aprobación), el número de ventas (*Estimated owners*), y la cantidad de jugadores simultáneos (*Peak CCU*). Con esto, se busca sentar las bases para crear modelos predictivos que estimen el éxito comercial de futuros desarrollos y descubrir qué características se necesitan para triunfar dentro de nichos específicos de mercado.

III. DESCRIPCIÓN DEL CONJUNTO DE DATOS

Se utilizó el "Steam Games Dataset" [1], obtenido a partir de la API oficial de Steam. Este *dataset* cuenta con 122 611 registros, correspondientes cada uno a un videojuego único, y está compuesto por 39 variables originales.

Las variables abarcan diferentes tipos (ver Figura 1): nominales absolutas como el identificador (*AppID*) y nombre (*Name*); de razón para características continuas como el precio (*Price*) y la máxima cantidad de jugadores simultáneos (*Peak CCU*); ordinales como la estimación de compradores (*Estimated owners*); y variables con múltiples valores nominales, como los géneros (*Genres*) y categorías (*Categories*).




Figura 1. Distribución de frecuencias para las variables numéricas de Steam. Se evidencia una gran asimetría hacia el lado izquierdo.

IV. ANÁLISIS EXPLORATORIO Y RESULTADOS

IV-A. Análisis de Frecuencias y Medidas de Centralidad

En la exploración inicial, se observó que casi todos los juegos son compatibles con Windows, superando ampliamente a los desarrollos para Mac y Linux. Al revisar variables numéricas como el precio y el máximo de jugadores activos (*Peak CCU*), se evidenció que una porción muy pequeña de títulos acumula la gran mayoría de las cifras. Al existir tantos valores en cero o muy bajos, existe una enorme diferencia entre el promedio (media aritmética) y la mediana. Para mitigar el efecto de estos valores atípicos (*outliers*), se calculó la **media truncada** (*trimmed mean*), eliminando el 10 % de los datos más extremos de cada lado para obtener el comportamiento de un juego más “típico”.




Figura 2. Diagramas de caja (*Boxplots*) que muestran la gran cantidad de valores atípicos y la enorme dispersión generada por juegos sumamente populares.

IV-B. Medidas de Dispersión y Distribuciones

Para medir correctamente la dispersión de los datos sin afectar la precisión matemática a causa de los valores atípicos, se priorizó la **Desviación Media Absoluta (AAD)**. Como se observa en la estimación de densidad KDE y en los diagramas de caja (Figura 2), atributos monetarios y de popularidad tienen una distribución marcadamente inclinada hacia la cota inferior. El mercado comercial se compone de innumerables títulos de bajo costo o completamente gratuitos con muy poco impacto, que contrastan fuertemente frente a las grandes y escasas franquicias AAA o juegos virales.

IV-C. Causalidad Multivariada

Al utilizar medidas de correlación lineal (coeficiente de Pearson), se encontraron relaciones claras y fundamentales. Por ejemplo, existe una fuerte asociación directa entre la máxima cifra récord de jugadores (*Peak CCU*) y el volumen histórico de reseñas obtenidas (tanto positivas como negativas). Estos factores crecen directamente de acuerdo al volumen total de jugadores que atrae el título.

V. PREPROCESAMIENTO DE DATOS

Para asegurar que los datos del catálogo resulten óptimos para su uso en la fase de modelamiento algorítmico estadístico, se ejecutó un proceso riguroso de limpieza:

V-A. Selección y Eliminación de Atributos

Se descartaron todas las variables que no aportaban métricas relevantes para clasificar o predecir el éxito de un juego, tales como hipervínculos web, direcciones de correo de soporte y referencias multimedia promocionales (*Header image*, *Movies*, *Screenshots*). Adicionalmente, se eliminaron columnas que se encontraban casi completamente vacías o rellenas de valores en cero, como *User score* o *Required age*, ya que estas interferían con la integridad de los modelos predictivos.




Figura 3. Estimación de densidad (KDE) para visibilizar las frecuencias en los rangos discretos de la cantidad estimada de jugadores (*Estimated Owners*).

V-B. Tratamiento de Valores Faltantes (Nulos)

A través de la inspección sobre la ausencia de datos, se identificó que no figurar con un autor y empresa encargada (*Developer*) es comúnmente una señal relacionada a estafas o desarrollos falsos subidos a la red de Steam; por este motivo, se purgaron completamente las filas que carecían de dicho identificador. Por el contrario, es un comportamiento

normal que las variables categóricas o descriptivas queden en blanco (ej. *Genres*, *Tags*, *Publishers*) debido a la forma de registro de algunos títulos. Estos casos orgánicos ausentes fueron cubiertos sistemáticamente con el identificador de texto "NA" para evitar corrupciones estructuradas. Toda métrica unívocamente matemática registró niveles completos, por lo que no existieron vacíos numéricos que imputar.

V-C. Ingeniería de Atributos y Discretización

El preprocesamiento del precio exhibía un desafío dada la enorme recurrencia de valores nominales fijados en \$0.00. Para contrarrestarlo, la cifra escalar *Price* fue extraída bajo bandas de clasificación ordinales (*Price_category*), replicando las barreras comerciales comúnmente encontradas entre consumidores (juegos gratuitos, juegos muy baratos, o el tope tradicional de \$59.99). De igual forma lógica, la cadena textual correspondiente a la fecha de publicación (*Release date*) se separó minuciosamente en tres diferentes campos tabulares: año, mes, y estación de lanzamiento. Esto habilitará la futura extracción estacional de picos de consumo anual.

V-D. Manejo Condicional de Valores Atípicos

La estrategia para atenuar valores atípicos se dictaminó con el algoritmo clásico del rango intercuartílico (IQR). En el campo preciso de los análisis tarifarios, se evidenció que aislar en dos sub-estratos independientes a los títulos "Gratuitos" en relación a aquellos de "Pago", provocaba un impacto determinante para comprender o fijar el límite estadístico a partir de cuándo un valor era realmente un costo sumamente atípico. Referente a medidas de popularidad de éxito irruptivo tales como la congregación máxima histórica (*Peak CCU*), se optó intencionalmente por conservar intactos todos sus datos hiper-extendidos. Esto obedece a que limitar arbitrariamente dichos volúmenes resultaría en amputar a los protagonistas absolutos y al concepto fundamental del "éxito", mermando completamente las proyecciones algorítmicas hacia los verdaderos gigantes del mercado de videojuegos.

V-E. Categorización de atributos

Para facilitar el análisis de las reseñas, se crearon nuevas columnas con información derivada. Para empezar se crearon las columnas *total_reviews* y *review_rate*. La primera es el total de reseñas que tiene un juego, mientras que la segunda es la tasa de reseñas positivas, calculada con la división entre las reseñas positivas (*Positive*) y las reseñas totales. Con la tasa se realizó una categorización para manejar las reseñas, esta refleja la que se usa en la plataforma. Para empezar se analiza el número de reseñas, si son cero se asigna la categoría *No reviews*, y si son menos de diez se tiene *Too few reviews*. A partir de aquí, se toma la tasa para asignar las categorías además del número de reseñas, como se observa en la tabla I

También se creó una categorización para las ventas, con el atributo "No data" para aquellos juegos sin ventas. En la tabla II se tienen las categorías para las ventas.

Adicionalmente, se tiene la categoría "Mega Hit" para los juegos que tengan más de 50000000 de ventas.

Categorías	Reseñas mínimas	Tasa mínima
Overwhelmingly Positive	500	0,95
Very Positive	10	0,8
Mostly Positive	10	0,7
Mixed	10	0,4
Mostly Negative	10	0,2
Overwhelmingly Negative	500	0,2
Very Negative	50	0,2

Cuadro I

RESEÑAS Y TASAS MÍNIMAS PARA CATEGORIZAR LAS RESEÑAS.

Categorías	Ventas Máximas
Niche	20000
Small Indie	100000
Growing	500000
Popular	1000000
Very Popular	2000000
Top Game	10000000
Blockbuster	50000000

Cuadro II

CATEGORÍAS PARA LAS VENTAS.

Por último, también se tiene una categorización de desempeño con base en las métricas del pico de usuarios concurrentes ("Peak CCU") y la calificación de la página agregadora de reseñas Metacritic.

Para los usuarios concurrentes se realiza una clasificación por percentiles con los valores de 0.25, 0.5, 0.75 y 0.9. Estos definen las categorías, los juegos con un valor de 0 son asignados a la categoría "No activity", mientras que los demás se asignan a las categorías "Very Low", "Low", "Medium", "High". Los juegos en el percentil más alto entran en la categoría "Very High".

Respecto a la calificación de Metacritic, la clasificación se hace teniendo en cuenta ciertos sesgos de la plataforma, donde la calificación de muchos juegos tiende a estar entre 50 y 100, y rara vez se otorga una clasificación menor a 50. Con esto en mente se tienen las categorías "Not rated" para juegos sin calificación, "Poor" para aquellos con menos de 50, "Mediocre" hasta 60, "Average" hasta 70, "Good" hasta 80, "Very Good" hasta 90 y "Excellent" para los juegos con una calificación entre 91 y 100.

V-F. Juegos de interés

Para analizar distintas tendencias se hizo una selección separada de ciertos juegos particularmente exitosos, estos fueron denominados como juegos de interés. Para seleccionar estos juegos se decidieron las medidas de reseñas y ventas, seleccionando los juegos con reseñas de Steam en las categorías Overwhelmingly Positive o Very Positive, o ventas en las categorías Top Game, Blockbuster o Mega Hit.

V-G. Uso de One-Hot Encoding

Se realizó el One-Hot Encoding en los atributos de "Genre", "Tags" para facilitar el análisis. Sobre los géneros se realizó la codificación sobre los 33 géneros únicos del dataset, mientras que para las etiquetas solo se usaron aquellas que tengan al menos 5000 apariciones para evitar tener columnas demasiado dispersas, conservando 59 de las 452 etiquetas presentes en el dataset.

	antecedents	consequents	support	confidence	lift
1	cat=Steam Trading Cards, tag=2D	target=review_good	0.023683	0.836116	2.361186
2	DLC=1-2, tag=Story Rich	target=review_good	0.022834	0.807371	2.280008
3	cat=Steam Cloud, tag=Anime	target=review_good	0.024086	0.801749	2.264134
4	cat=Steam Trading Cards, tag=Singleplayer	target=review_good	0.043635	0.797248	2.251421
5	cat=Steam Cloud, tag=Story Rich	target=review_good	0.034868	0.793186	2.239951
6	DLC=1-2, tag=Atmospheric	target=review_good	0.020880	0.791764	2.235934
7	cat=Steam Cloud, tag=Female Protagonist	target=review_good	0.021240	0.785298	2.217675
8	DLC=1-2, tag=2D	target=review_good	0.030226	0.773247	2.183643
9	cat=Steam Cloud, tag=Funny	target=review_good	0.023578	0.772675	2.182028
10	cat=Steam Cloud, cat=Steam Trading Cards	target=review_good	0.043539	0.765476	2.161698

Cuadro III

REGLAS PARA BUENAS RESEÑAS CON FP-GROWTH CON 126 REGLAS
 TOTALES

VI. ANÁLISIS DE REGLAS DE ASOCIACIÓN

En esta sección se aplicaron los algoritmos Apriori y FP-Growth para generar reglas de asociación con base en los géneros y las etiquetas. Para empezar se realizó el análisis del dataset completo usando ciertas características de los juegos como antecedentes y métricas de éxito como consecuentes. Posteriormente se pasó al análisis de los juegos de interés, generando reglas de asociación entre géneros y etiquetas para obtener información específica a estos juegos. Por último se analizaron los juegos de interés para obtener las características que conducen a una calificación extremadamente positiva entre estos juegos.

VI-A. Análisis del dataset completo

Para el análisis del dataset completo se usaron como antecedentes las columnas que se consideraron útiles para predecir el éxito de un juego: `genre` y `tag` definen el contenido y estilo del juego, `Categories` da los modos de juego disponibles, `Price_category` define el precio del juego, `Release_season` y `Release_year` hablan del contexto del mercado, `Windows`, `Mac`, `Linux` dan el alcance de la plataforma y, por último, `DLC_count` y `Discount` se toman en bins y dan los contenidos descargables disponibles y los descuentos aplicados a los precios.

Respecto a los consecuentes, se seleccionaron como medidas de éxito la calificación de los juegos (`review_score_cat`) con el objetivo de reseñas favorables, el volumen de reseñas (`total_reviews`) con los objetivos de reseñas por encima del percentil 50, las ventas (`sales_cat`) con el objetivo `sales_good` y el pico de usuarios concurrentes (`ccu_cat`) con el objetivo `ccu_good`.

Durante la aplicación de los algoritmos se pusieron restricciones a los soportes mínimo y máximo para descartar items raros y descartar items demasiado comunes (poco informativos).

Las tablas desde la III hasta la XII muestran las 10 mejores reglas generadas por los dos algoritmos para cada consecuente, seguido de las 10 reglas globales más frecuentes.

VI-B. Análisis de los juegos de interés

En los juegos de interés se utilizó el algoritmo Apriori para encontrar las relaciones entre géneros para encontrar las combinaciones más frecuentes. Con este algoritmo se encontraron 2288 reglas de asociación, ilustradas con su soporte y confianza en la figura 4. Las 10 reglas con mayor lift se ilustran en la figura 5.

	antecedents	consequents	support	confidence	lift
1	tag=Visual Novel	target=review_good	0.034360	0.673708	1.902545
2	cat=Steam Trading Cards	target=review_good	0.066933	0.673245	1.901238
3	tag=Anime	target=review_good	0.047331	0.662174	1.869973
4	tag=Difficult	target=review_good	0.035814	0.644140	1.819046
5	tag=Story Rich	target=review_good	0.074404	0.636616	1.797798
6	tag=Female Protagonist	target=review_good	0.041945	0.631878	1.784417
7	tag=Comedy	target=review_good	0.032932	0.629289	1.777106
8	tag=Multiple Endings	target=review_good	0.028746	0.614032	1.734021
9	tag=Funny	target=review_good	0.053007	0.613855	1.733523
10	tag=Cute	target=review_good	0.066635	0.600047	1.694529

Cuadro IV

REGLAS PARA BUENAS RESEÑAS CON APRIORI CON 37 REGLAS TOTALES

	antecedents	consequents	support	confidence	lift
1	tag=Co-op	target=sales_good	0.007769	0.168695	7.679673
2	tag=Multiplayer	target=sales_good	0.012297	0.138407	6.300827
3	tag=Open World	target=sales_good	0.007191	0.137016	6.237507
4	cat=Steam Trading Cards	target=sales_good	0.011544	0.116113	5.285925

Cuadro V

REGLAS PARA BUENAS VENTAS CON FP-GROWTH CON 4 REGLAS
 TOTALES

	antecedents	consequents	support	confidence	lift
1	tag=Multiplayer	target=ccu_good	0.017298	0.194696	4.605192
2	cat=Steam Trading Cards	target=ccu_good	0.016624	0.167210	3.955050
3	cat=Co-op	target=ccu_good	0.011412	0.118401	2.800556
4	cat=Multi-player	target=ccu_good	0.017902	0.100839	2.385157
5	DLC=1-2	target=ccu_good	0.012402	0.100276	2.371853

Cuadro VI

REGLAS PARA BUENAS VENTAS CON APRIORI CON 4 REGLAS TOTALES

	antecedents	consequents	support	confidence	lift
1	cat=Steam Trading Cards, tag=Story Rich	target=reviews_50p_plus	0.021853	0.998000	1.955074
2	cat=Steam Trading Cards, tag=Atmospheric	target=reviews_50p_plus	0.021975	0.996822	1.952766
3	cat=Steam Trading Cards, tag=RPG	target=reviews_50p_plus	0.023053	0.992459	1.944219
4	cat=Steam Trading Cards, tag=Adventure	target=reviews_50p_plus	0.046184	0.991725	1.942781
5	cat=Steam Trading Cards, tag=Strategy	target=reviews_50p_plus	0.022982	0.991686	1.942705
6	cat=Steam Trading Cards, tag=Action	target=reviews_50p_plus	0.045860	0.987179	1.933877
7	cat=Steam Trading Cards, tag=Indie	target=reviews_50p_plus	0.061800	0.985613	1.930808
8	Release_era=2010-2019, cat=Steam Trading Cards	target=reviews_50p_plus	0.069315	0.979819	1.919459
9	Release_era=2010-2019, tag=Female Protagonist	target=reviews_50p_plus	0.020162	0.962375	1.885285
10	Discount=51-75, cat=Steam Trading Cards	target=reviews_50p_plus	0.021485	0.961584	1.883735

Cuadro VII

REGLAS PARA RESEÑAS EN EL PERCENTIL 50 CON FP-GROWTH CON 192
 REGLAS TOTALES

	antecedents	consequents	support	confidence	lift
1	cat=Steam Trading Cards	target=reviews_50p_plus	0.092508	0.930491	1.822824
2	tag=Co-op	target=reviews_50p_plus	0.038249	0.830544	1.627029
3	tag=Anime	target=reviews_50p_plus	0.059252	0.828943	1.623892
4	tag=Difficult	target=reviews_50p_plus	0.045466	0.817738	1.601942
5	Discount=76+	target=reviews_50p_plus	0.058971	0.813262	1.593175
6	tag=Visual Novel	target=reviews_50p_plus	0.041270	0.809205	1.585226
7	tag=Multiplayer	target=reviews_50p_plus	0.071785	0.807965	1.582798
8	tag=Psychological Horror	target=reviews_50p_plus	0.042996	0.804754	1.576507
9	Release_era=2010-2019	target=reviews_50p_plus	0.211248	0.803859	1.574755
10	tag=Female Protagonist	target=reviews_50p_plus	0.053138	0.800501	1.568176

Cuadro VIII

REGLAS PARA RESEÑAS EN EL PERCENTIL 50 CON APRIORI CON 37
 REGLAS TOTALES

	antecedents	consequents	support	confidence	lift
1	cat=Steam Trading Cards, tag=Atmospheric	target=reviews_75p_plus	0.020872	0.946762	3.783138
2	cat=Steam Trading Cards, tag=Story Rich	target=reviews_75p_plus	0.020626	0.942000	3.764110
3	cat=Steam Trading Cards, tag=RPG	target=reviews_75p_plus	0.020819	0.896305	3.581517
4	cat=Steam Trading Cards, tag=Adventure	target=reviews_75p_plus	0.040613	0.872108	3.484832
5	cat=Steam Trading Cards, tag=Strategy	target=reviews_75p_plus	0.020153	0.869615	3.474867
6	DLC=1-2, cat=Steam Trading Cards	target=reviews_75p_plus	0.026565	0.859938	3.436199
7	Release_era=2010-2019, tag=Multiplayer	target=reviews_75p_plus	0.025277	0.842628	3.367031
8	cat=Steam Cloud, cat=Steam Trading Cards	target=reviews_75p_plus	0.047822	0.840776	3.359632
9	cat=Steam Trading Cards, platform=Mac	target=reviews_75p_plus	0.030602	0.824445	3.294377
10	Release_era=2010-2019, cat=Steam Trading Cards	target=reviews_75p_plus	0.056983	0.805497	3.218662

Cuadro IX

REGLAS PARA RESEÑAS EN EL PERCENTIL 75 CON FP-GROWTH CON 87
 REGLAS TOTALES

	antecedents	consequents	support	confidence	lift
1	cat=Steam Trading Cards	target=reviews_75p_plus	0.079020	0.794820	3.175997
2	tag=Co-op	target=reviews_75p_plus	0.027038	0.587105	2.345997
3	tag=Multiplayer	target=reviews_75p_plus	0.051089	0.575020	2.297704
4	tag=Anime	target=reviews_75p_plus	0.038555	0.539395	2.155351
5	tag=Open World	target=reviews_75p_plus	0.028027	0.534045	2.133976
6	DLC=1-2	target=reviews_75p_plus	0.063193	0.510941	2.041655
7	Discount=76+	target=reviews_75p_plus	0.036777	0.507187	2.026653
8	tag=Female Protagonist	target=reviews_75p_plus	0.033414	0.503365	2.011379
9	tag=Story Rich	target=reviews_75p_plus	0.057798	0.494529	1.976075
10	Release_era=2010-2019	target=reviews_75p_plus	0.122497	0.466138	1.862626

Cuadro X

REGLAS PARA RESEÑAS EN EL PERCENTIL 75 CON APRIORI CON 34
REGLAS TOTALES

	antecedents	consequents	support	confidence	lift
1	tag=Co-op	target=sales_good	0.007769	0.168695	7.679673
2	tag=Multiplayer	target=sales_good	0.012297	0.138407	6.300827
3	tag=Open World	target=sales_good	0.007191	0.137016	6.237507
4	cat=Steam Trading Cards	target=sales_good	0.011544	0.116113	5.285925
5	tag=Multiplayer	target=ccu_good	0.017298	0.194696	4.605192
6	cat=Steam Trading Cards	target=ccu_good	0.016624	0.167210	3.955050
7	cat=Steam Trading Cards, tag=Atmospheric	target=reviews_75p_plus	0.020872	0.946762	3.783138
8	cat=Steam Trading Cards, tag=Story Rich	target=reviews_75p_plus	0.020626	0.942000	3.764110
9	cat=Steam Trading Cards, tag=RPG	target=reviews_75p_plus	0.020819	0.896305	3.581517
10	cat=Steam Trading Cards, tag=Adventure	target=reviews_75p_plus	0.040613	0.872108	3.484832

Cuadro XI

TOP 10 REGLAS CON FP-GROWTH

	antecedents	consequents	support	confidence	lift
1	tag=Co-op	target=sales_good	0.007769	0.168695	7.679673
2	tag=Multiplayer	target=sales_good	0.012297	0.138407	6.300827
3	tag=Open World	target=sales_good	0.007191	0.137016	6.237507
4	cat=Steam Trading Cards	target=sales_good	0.011544	0.116113	5.285925
5	tag=Multiplayer	target=ccu_good	0.017298	0.194696	4.605192
6	cat=Steam Trading Cards	target=ccu_good	0.016624	0.167210	3.955050
7	cat=Steam Trading Cards	target=reviews_75p_plus	0.079020	0.794820	3.175997
8	cat=Co-op	target=ccu_good	0.011412	0.118401	2.800556
9	cat=Multi-player	target=ccu_good	0.017902	0.100839	2.385157
10	DLC=1-2	target=ccu_good	0.012402	0.100276	2.371853

Cuadro XII

TOP 10 REGLAS CON APRIORI




Figura 4. Reglas de asociación de los juegos de interés.




Figura 5. Reglas con mayor lift en el primer análisis.

Sin embargo, muchas de las reglas descubiertas con este método corresponden a jerarquías naturales de clasificación, como es el caso de la regla Psychological Horror -> Horror, o conceptos sumamente amplios. Por esto se aplicaron dos estrategias de filtrado avanzado: la primera es la exclusión de etiquetas genéricas ("Stop-Tags"), donde se retiran ciertas etiquetas que no aportan diferenciación. La segunda es el análisis de reglas complejas, donde se buscan reglas con al menos 3 elementos para obtener información más valiosa.




Figura 6. Reglas con mayor lift en el análisis con las dos estrategias aplicadas.

Al aplicar estas dos estrategias, se obtuvieron 2060 reglas, de las cuales las 10 con mayor lift se encuentran en la figura 6.




Figura 7. Reglas con mayor lift en el análisis con las dos estrategias aplicadas.

A continuación, se realizó el análisis de los juegos de interés orientado a la creación de reglas con el consecuente "Overwhelmingly Positive" en la variable review_score_cat. Las 10 combinaciones que tienen este consecuente se muestran en la figura 7.

Por último, se realizó la ejecución del algoritmo FP-Growth sobre los mismos datos, obteniendo resultados idénticos en las reglas pero con una mejora notable en el desempeño del algoritmo, obteniendo el mismo número de itemsets 4.7 veces más rápidamente.

VII. ANÁLISIS DE LA AGRUPACIÓN

Para realizar un análisis de los juegos según su rendimiento se realizó el agrupamiento de los juegos de interés. Este tipo

de análisis también se intentó con el dataset completo. Sin embargo, debido a la cantidad de datos, los análisis intentados no se pudieron completar.

VII-A. Análisis del dataset completo

Para la agrupación se seleccionaron como variables el porcentaje de reseñas positivas (Positive), el número de compradores estimado (Estimated owners) y el pico de jugadores concurrentes (Peak CCU). Se eliminaron las filas con valores nulos en estas variables y se normalizaron.

```

Búsqueda del número óptimo de clusters usando Elbow Method...
n_clusters=2: Inertia=170380.51, Silhouette (muestra)=-1.0000
n_clusters=3: Inertia=92984.07, Silhouette (muestra)=0.9962
n_clusters=4: Inertia=59509.42, Silhouette (muestra)=0.9962
n_clusters=5: Inertia=43720.07, Silhouette (muestra)=0.9907
n_clusters=6: Inertia=34286.44, Silhouette (muestra)=0.9861
n_clusters=7: Inertia=28835.07, Silhouette (muestra)=0.9793
n_clusters=8: Inertia=23745.83, Silhouette (muestra)=0.9793

✓ Número óptimo encontrado: 3 clusters (máximo Silhouette)

```

Figura 8. Valores generados con cada n usando el algoritmo K-Means.

Se utilizó primero el algoritmo K-Means con distintas cantidades de clusters, esto con el objetivo de encontrar el valor que maximizara el Silhouette, el cual fue de 3 clusters. Los resultados se muestran en la figura 8.

```

Búsqueda de número óptimo de componentes:
BIC (criterio Bayesiano de información):
n_components=2: BIC=-2557449.81
n_components=3: BIC=-2589528.65
n_components=4: BIC=-2599844.58
n_components=5: BIC=-2912654.67
n_components=6: BIC=-3049785.60
n_components=7: BIC=-3072747.89
n_components=8: BIC=-3090260.03 <-- Óptimo
n_components=9: BIC=-3073973.57
n_components=10: BIC=-3075716.22

```

Figura 9. Valores generados con cada n en el algoritmo GMM.

Para la segunda prueba se utilizó el algoritmo GMM (Gaussian Mixture Model). En este se utilizó el criterio Bayesiano de información para obtener el número óptimo de n, el cuál fue de 8. Esto se evidencia en la figura 9.

A pesar de que los dos algoritmos se ejecutaron exitosamente, no fue posible obtener más información de los clusters debido a que no se pudo ejecutar el código para la comparación y la graficación en tres dimensiones.

VII-B. Análisis de los juegos de interés

En el caso de los juegos de interés se empleó primero el algoritmo K-means sobre cuatro variables que definen el perfil comercial del juego: El precio (Price), pico de usuarios concurrentes Peak CCU, porcentaje de reseñas positivas (Positive) y promedio de tiempo jugado Average




Figura 10. Gráfica de codo generada para los juegos de interés con el algoritmo K-Means.

playtime forever. De manera similar al análisis de los datos en genral primero se normalizaron los datos y más adelante se usó el método del codo para encontrar el número óptimo de clusters. Este método se encuentra graficado en la figura 10.

	Price	Peak CCU	Positive	Average playtime forever	Cantidad de Juegos
Cluster_Perfil					
0	3.64	59.64	2894.11	319.29	18532
1	0.00	818938.50	4839613.50	43985.00	2
2	17.98	670.48	15327.92	1272.33	2844
3	3.79	37.17	524.75	179459.42	12

Figura 11. Tabla generada con los promedios de las variables en cada cluster.

Se tomó el valor n como cuatro, y los valores promedio de cada cluster se encuentran en la figura 11.

Con estas métricas se puede hacer un análisis de cada cluster para comprender los perfiles comerciales de los juegos exitosos.

- **Éxito general:** El cluster más grande tiene precios accesibles y tiempos de juego cercanos al promedio.
- **Juegos premium:** En este grupo los juegos tienen un valor más elevado, con grandes cantidades de reseñas positivas y altos picos de jugadores.
- **Juegos Idle:** Unos pocos juegos con bajos precios, reseñas y jugadores, pero con una cantidad muy alta de tiempo de juego. Estos juegos son aquellos que se pueden dejar corriendo de fondo mientras los usuarios hacen otras tareas.
- **Duopolio Free-to-play:** El último cluster lo componen solo dos juegos: Counter-Strike 2 y Dota 2. Estos dos juegos son gratuitos, con una gran cantidad de usuarios y tiempo de juego. Se podría considerar que estos juegos tienen un ecosistema económico independiente.

Para robustecer el análisis del algoritmo K-Means se aplica una transformación logarítmica a los datos para reducir el




Figura 12. Gráfica de código del algoritmo K-Means en los juegos con reseñas muy positivas con los datos con transformación logarítmica.

impacto de juegos con métricas extremas y se busca comprender la razón por la que ciertos juegos tienen la calificación *Overwhelmingly Positive*. El análisis genera la gráfica de código de la figura 12.

Número de Clúster	Price	Peak CCU	Positive	Average playtime forever	Cantidad de Juegos
0	2.16	14.67	4118.61	343.86	402
1	1.84	24.92	8622.17	0.49	80
2	10.84	42.61	3033.54	2196.33	496
3	9.13	3365.23	106644.38	2282.69	288

Figura 13. Clusters generados por el algoritmo K-Means usando datos con transformación logarítmica.

Con esta ejecución del algoritmo se encontraron los clusters de la figura 13.

Con los dos análisis se encontraron dos grandes divisiones:

- Entre los juegos de precio medio/alto se encontraron dos grupos con buenas retenciones de juego, pero diferenciados por la popularidad, representada en el pico de usuarios concurrentes. Por un lado se tienen juegos muy conocidos con un CCU muy elevado, y por otro juegos aclamados pero menos populares, con buena retención pero un bajo pico de usuarios concurrentes.
- Entre los juegos gratuitos o de bajo costo se tiene una división basada en el tiempo de juego promedio, con una división entre los juegos con un tiempo de juego razonable y aquellos con muy poco tiempo, catalogados como herramientas o registros erróneos.

Para realizar una comparación, se utilizaron otros dos algoritmos para realizar una comparativa entre las tres grandes familias de clustering no supervisado. Como K-Means es un algoritmo particional, su utilizó Agglomerative Clustering para tener un algoritmo jerárquico y DBSCAN para uno basado en densidad. El rendimiento de cada algoritmo es evaluado con el




Figura 14. Rendimiento de los algoritmos evaluados con base en el coeficiente de Silueta.

coeficiente de Silueta, una métrica que penaliza agrupaciones difusas y premia fronteras naturales y bien cohesionadas. Los resultados de la evaluación del coeficiente de Silueta se encuentran en la figura 14.

Con estas métricas se confirma que en este caso el algoritmo K-Means provee la mejor interpretación del dataset, mientras que los otros dos algoritmos tienen más problemas.

Por un lado el algoritmo jerárquico Agglomerative Clustering obtuvo el coeficiente de Silueta más baja, esto se puede explicar por la presencia de una gran cantidad de registros similares, como una nube de datos. Este algoritmo realiza cortes arbitrarios, reduciendo la precisión de los clusters generados.

Por otra parte, DBSCAN presenta la falla de considerar los vecinos para generar un cluster, lo que deja a muchos juegos importantes por su éxito anormal como anomalías o ruido, lo que disminuye el valor de la información obtenida.

VIII. ANÁLISIS DE CLASIFICACIÓN

VIII-A. Análisis del dataset completo

En esta etapa se abordó la clasificación supervisada sobre el conjunto de datos completo de juegos de Steam, con el objetivo de predecir si un título alcanzaría una valoración positiva alta a partir de sus atributos estructurales, temporales y de recepción por parte de los usuarios. Para ello, se construyó una variable objetivo binaria a partir de *review_score_cat*, considerando como clase positiva los juegos *Very Positive* y *Overwhelmingly Positive*. Los registros etiquetados como *No reviews* y *Too few reviews* fueron excluidos, puesto que no ofrecen evidencia suficiente para inferir con fiabilidad la calidad percibida del producto.

Sobre este conjunto depurado se efectuó una verificación exhaustiva de las variables candidatas al modelado. Se revisó la integridad de las columnas numéricas, la ausencia de valores faltantes y la correcta naturaleza binaria de las variables derivadas por One-Hot Encoding para géneros y etiquetas. De manera complementaria, se descartaron variables susceptibles de inducir fuga de información, en particular aquellas que derivan de la propia calificación o de estadísticas que la definen de forma casi determinista. Esta depuración fue necesaria para

asegurar que los modelos aprendieran patrones explicativos y no reglas indirectas de reconstrucción de la clase objetivo.

La partición de los datos se realizó mediante un esquema holdout estratificado 80/20, con el propósito de conservar la proporción de clases en ambos subconjuntos. Este paso es especialmente relevante cuando se trabaja con clases desbalanceadas, ya que una partición aleatoria no estratificada podría distorsionar el error aparente y comprometer la comparabilidad entre experimentos. Adicionalmente, se aplicó escalamiento estándar únicamente sobre las variables numéricas continuas, preservando intactas las variables binarias. Esta decisión mantuvo la semántica original de las columnas codificadas y evitó introducir transformaciones innecesarias sobre atributos que ya se encontraban en una escala natural de 0 y 1.

La comparación de modelos incluyó tres enfoques con propiedades complementarias. El Árbol de Decisión aportó interpretabilidad mediante reglas explícitas; Naïve Bayes Gaussiano ofreció una referencia probabilística simple y eficiente; y la red neuronal de tipo perceptrón multicapa (MLP) permitió capturar relaciones no lineales entre variables heterogéneas. Dado el desbalance de clases observado en la variable objetivo, la evaluación no se apoyó exclusivamente en la exactitud, sino en métricas más sensibles al desempeño de la clase minoritaria, tales como *precision*, *recall*, *F1-score* y *ROC-AUC*. La validación cruzada estratificada de 10 pliegues complementó el holdout y aportó una estimación más estable del comportamiento de cada clasificador frente a distintas particiones del conjunto de entrenamiento.




Figura 15. Distribución de la variable objetivo y comparación con clasificadores ingenuos.

En términos metodológicos, el análisis evidenció que la exactitud por sí sola puede resultar engañosa en escenarios desbalanceados: un clasificador trivial puede alcanzar una puntuación elevada sin identificar adecuadamente la clase de interés. Por ello, se dio prioridad al estudio conjunto de las matrices de confusión, las curvas ROC y las métricas orientadas a la clase positiva, las cuales permiten valorar de forma más realista el poder discriminativo del modelo. En síntesis, este bloque estableció una línea base sólida para la clasificación supervisada del conjunto completo de juegos y proporcionó criterios consistentes para interpretar los experimentos posteriores.

VIII-B. Análisis de los juegos de interés

El segundo experimento se concentró en el subconjunto de juegos de mayor interés analítico, compuesto por títulos




Figura 16. Evaluación comparativa de los clasificadores sobre el conjunto de prueba.

con reseñas suficientemente confiables y orientado a distinguir entre *Very Positive* y *Overwhelmingly Positive*. A diferencia del análisis general, en este caso el objetivo fue explorar con mayor detalle los factores que acompañan la excelencia sostenida en la recepción del público, utilizando variables de precio, tiempos de juego, plataformas, géneros y etiquetas de Steam. Esta formulación permite estudiar no solo qué juegos triunfan, sino también qué configuraciones de atributos tienden a separar a los títulos altamente valorados del conjunto de juegos positivamente recibidos.

El procedimiento inició con la construcción del conjunto de características a partir de variables numéricas seleccionadas y codificaciones binarias ya disponibles en el preprocesamiento previo. Se conservaron atributos que describen el comportamiento comercial y de uso del juego, como el precio, el pico de usuarios concurrentes, los tiempos de juego promedio y mediano, además de las banderas binarias de sistema operativo, géneros y etiquetas frecuentes. Para evitar contaminación entre entrenamiento y prueba, se aplicó una partición estratificada y se escaló únicamente el bloque numérico. Esta separación fue necesaria porque el conjunto de atributos combina variables continuas con indicadores binarios dispersos, cuya escala no debe homogeneizarse indiscriminadamente.

Debido a que la clase positiva minoritaria representa el caso de mayor interés, se incorporaron estrategias específicas para contrarrestar el desbalance. Entre ellas destacan el uso de pesos de clase en los modelos sensibles a la distribución, la optimización del umbral de decisión a partir de la




Figura 17. Distribución de clases en los juegos de interés.

curva Precision-Recall y, en el caso de la red neuronal, un esquema de submuestreo del conjunto de entrenamiento. Esta combinación de medidas buscó reducir el sesgo hacia la clase mayoritaria y mejorar la recuperación de títulos que realmente alcanzan la categoría de excelencia máxima.

Se compararon varios modelos con distinta naturaleza inductiva: un Random Forest como referencia robusta sobre datos tabulares, un HistGradientBoostingClassifier, una Regresión Logística y una red neuronal MLP. Cada uno de ellos ofrece una perspectiva distinta sobre el problema: los modelos de ensemble explotan la interacción entre variables sin requerir supuestos fuertes, la Regresión Logística funciona como baseline lineal sobre un espacio de alta dimensión y la red neuronal introduce capacidad no lineal adicional. La evaluación se diseñó alrededor de métricas sensibles al desbalance, en especial *F1-score* optimizado y *Precision-Recall AUC*, ya que estos indicadores reflejan mejor la capacidad del modelo para identificar la clase positiva rara sin inflar artificialmente el rendimiento mediante la clase mayoritaria.




Figura 18. Comparación de modelos mediante curvas Precision-Recall y matrices de confusión.

Los resultados permitieron observar que el ajuste del umbral de decisión tiene un impacto sustantivo en la recuperación de la clase positiva, especialmente en contextos de fuerte asimetría entre clases. En particular, la optimización del umbral mediante la maximización del *F1-score* resulta más informativa que el umbral fijo de 0,5, porque reduce falsos negativos y mejora la sensibilidad respecto del grupo minoritario, que es precisamente el de mayor interés analítico. Asimismo, la comparación entre modelos mostró que los




Figura 19. Comparación de la red neuronal original y la versión optimizada.

métodos de ensemble y la red neuronal optimizada ofrecen alternativas complementarias: los primeros aportan robustez y estabilidad, mientras que la red neuronal puede beneficiarse de una estrategia explícita de balanceo y regularización cuando se entrena sobre datos submuestreados.

En conjunto, este análisis proporciona una caracterización más fina de los juegos de interés y de los rasgos que acompañan a las calificaciones más altas dentro del ecosistema de Steam. Además de confirmar la utilidad de las métricas centradas en la clase positiva, el estudio refuerza la idea de que, en problemas desbalanceados, la selección del umbral y la estrategia de balanceo influyen de manera decisiva en la calidad práctica del clasificador.

IX. CONCLUSIÓN Y TRABAJOS FUTUROS

El presente trabajo permitió estudiar de manera integral el ecosistema de videojuegos de Steam mediante la aplicación de técnicas de análisis exploratorio, preprocesamiento, minería de patrones y aprendizaje automático sobre un conjunto de más de 122 000 títulos. Los resultados obtenidos evidencian que el catálogo de Steam presenta una distribución fuertemente desigual, donde una pequeña proporción de juegos concentra gran parte de las ventas, las reseñas y la actividad de usuarios, mientras que la mayoría de los títulos mantienen niveles reducidos de visibilidad e impacto comercial.

La fase de preprocesamiento resultó fundamental para adaptar el conjunto de datos a tareas posteriores de análisis. La eliminación de atributos irrelevantes, el tratamiento de valores faltantes, la creación de variables derivadas y la discretización de métricas clave permitieron transformar información heterogénea en representaciones más adecuadas para los algoritmos de minería de datos. Asimismo, la conservación selectiva de ciertos valores extremos, particularmente aquellos asociados a métricas de popularidad, permitió preservar información esencial sobre los juegos más exitosos de la plataforma.

Los algoritmos de reglas de asociación revelaron patrones consistentes entre determinadas características de los videojuegos y sus indicadores de éxito. En particular, atributos relacionados con experiencias multijugador, cooperación entre jugadores, mundo abierto y ciertas funcionalidades propias de Steam mostraron asociaciones relevantes con mayores niveles de ventas, actividad concurrente y volumen de reseñas. Además, el análisis de los juegos de interés permitió identificar combinaciones de géneros y etiquetas que aparecen frecuentemente en títulos con valoraciones excepcionalmente

positivas, aportando evidencia sobre preferencias recurrentes de la comunidad de usuarios.

El análisis de agrupamiento mostró que incluso dentro de los juegos exitosos existen perfiles claramente diferenciados. Se identificaron grupos asociados a títulos premium de alta popularidad, juegos de nicho con elevada retención de usuarios, productos de bajo costo con patrones de uso particulares y casos excepcionales representados por fenómenos masivos como Counter-Strike 2 y Dota 2. La comparación entre K-Means, Agglomerative Clustering y DBSCAN evidenció que los métodos particionales ofrecen una representación más adecuada para este conjunto de datos, debido a la presencia de distribuciones densas y numerosos valores extremos.

Por su parte, los experimentos de clasificación confirmaron que el éxito percibido de un videojuego puede modelarse de forma razonablemente efectiva utilizando atributos estructurales, comerciales y de comportamiento. Los resultados resaltan la importancia de emplear métricas adecuadas para conjuntos desbalanceados y demuestran que técnicas como la optimización de umbrales de decisión, el balanceo de clases y la selección cuidadosa de variables tienen un impacto significativo sobre la capacidad predictiva de los modelos. Además, la comparación entre árboles de decisión, modelos probabilísticos, métodos de ensamble y redes neuronales mostró que distintos enfoques ofrecen ventajas complementarias entre interpretabilidad y capacidad predictiva.

Como trabajo futuro, resulta especialmente interesante incorporar información temporal detallada sobre la evolución de precios, descuentos, actividad de usuarios y volumen de reseñas. Este tipo de información permitiría construir modelos dinámicos capaces de estudiar el ciclo de vida completo de un videojuego y no únicamente una fotografía estática de su estado actual. De igual manera, podría explorarse la aplicación de técnicas avanzadas de balanceo, métodos de ensamble más sofisticados y algoritmos de aprendizaje profundo orientados a mejorar la capacidad de generalización de los modelos predictivos.

Otra línea prometedora consiste en integrar fuentes de información externas, tales como datos provenientes de redes sociales, transmisiones en plataformas de streaming, tendencias de búsqueda o actividad en comunidades de jugadores. La combinación de estas fuentes con las métricas internas de Steam permitiría obtener una visión más completa de los factores que impulsan la popularidad y la recepción de un videojuego.

Finalmente, los resultados obtenidos sientan las bases para el desarrollo de sistemas de recomendación y herramientas de apoyo a la toma de decisiones dirigidas a desarrolladores, estudios independientes y editores. Estos sistemas podrían utilizar los patrones descubiertos para estimar el potencial de éxito de nuevos proyectos, identificar nichos de mercado poco explotados y apoyar estrategias de lanzamiento, monetización y posicionamiento dentro de la plataforma Steam.

REFERENCIAS

- [1] M. B. Roman, "Steam games dataset," 2022. [Online]. Available: <https://www.kaggle.com/ds/2109585>